

RAG42

基于检索增强生成的多跳问答系统

PolyU COMP5423 · 25Fall 课程项目

目录

1. 项目概述与问题定义
2. 系统架构总览
3. 检索模块 — 5 种检索器
4. 混合检索与重排序
5. 生成模块与 workflow
6. Agentic 多跳推理流程
7. 评估框架与实验结果

1. 项目概述

问题：多跳问答 (Multi-hop QA)

给定一个需要跨多个文档推理的复杂问题，系统需检索相关信息并生成准确答案。

示例问题：

“电影《绿皮书》的导演出生在哪个城市？”


需要两步推理：

1. 《绿皮书》的导演是谁？ → Peter Farrelly
2. Peter Farrelly 出生在哪里？ → Cumberland, Rhode Island

数据集

- HotpotQA — 经典多跳问答基准
- 课程提供的子集 `izhx/COMP5423-25Fall-HQ-small`
- 验证集 300 条多跳问题

2. 系统架构总览



3. 检索模块 — 5 种检索器

- **SparseRetriever**: 经典 BM25 算法，基于词频-逆文档频率，擅长精确关键词匹配
- **DenseRetriever**: BAAI/bge-large-en-v1.5 编码为 1024 维向量，FAISS 近邻搜索，捕获语义相似性
- **StaticEmbeddingRetriever**: Word2Vec 100 维静态词向量取平均作为文档表示
- **ColBERTRetriever**: token 级多向量检索，MaxSim 评分，精细度高但计算成本更大
- **HybridRetriever**: 核心方案，融合 BM25 + BGE + 交叉编码器重排

所有检索器继承 `BaseRetriever`，统一接口：

```
retrieve(query, k=20) -> List[Tuple[doc_id, doc_text, score]]
```

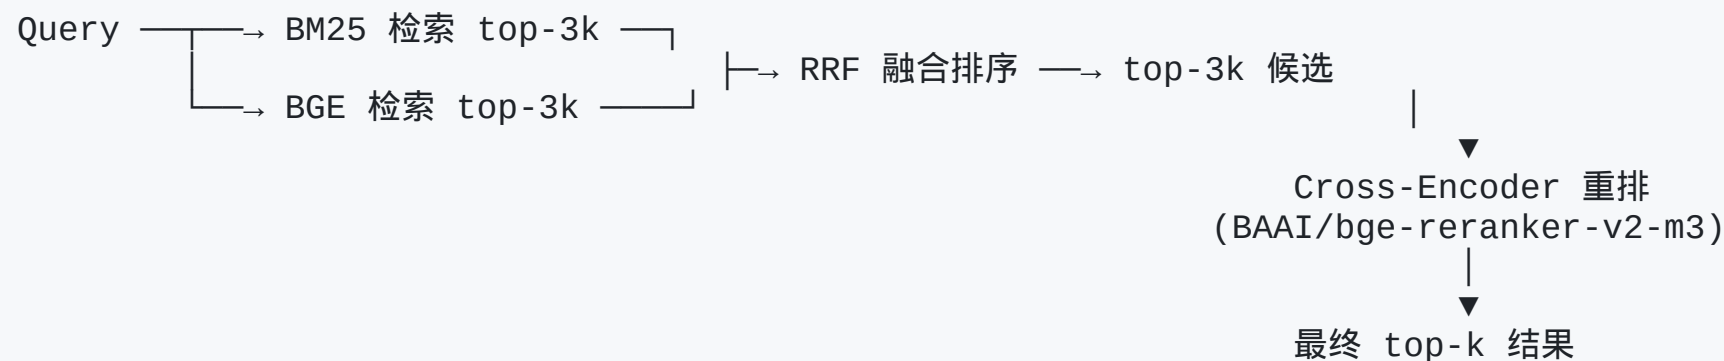
4. 混合检索 — 核心方案

Reciprocal Rank Fusion (RRF)

$$\text{score}(d) = \frac{1}{k + \text{rank}_{\text{BM25}}(d)} + \frac{1}{k + \text{rank}_{\text{BGE}}(d)}$$

其中 $k = 60$ (标准常数)

工作流程



效果： BM25 擅长关键词匹配，BGE 捕获语义，RRF 互补融合，交叉编码器精排。

5. 生成模块


两种 Generator

	HuggingfaceGenerator	OpenAIGenerator
模型	Qwen2.5-0.5B-Instruct (本地)	Qwen 系列 (远程 API)
推理方式	HuggingFace Transformers	Aliyun DashScope API
解码策略	确定性 (do_sample=False)	API 默认
适用场景	本地部署/无网络	更大模型/更好效果

System Prompt 设计原则

- 要求输出短语、实体名或 yes/no
- 禁止完整句子和解释
- 适配 HotpotQA 答案格式

6. Agentic 多跳推理流程



6.1 多跳推理 — 链式推理

子问题 1: “《绿皮书》的导演是谁?”

- 检索相关文档 → 生成答案: **Peter Farrelly**

子问题 2: “*Peter Farrelly* 出生在哪里?”

- 检索 + 注入子答案 1 作为上下文 → 生成答案: **Cumberland, Rhode Island**

综合: 将所有子答案传给 LLM, 生成最终答案。

关键机制

- 链式上下文传递 — 后续子问题可利用前序子答案
- 原始问题补充检索 — 避免分解后丢失全局信息
- 答案后处理 — 去除冗余前缀 (“The answer is:”), 统一格式

6.2 单跳路径 — 答案验证

当问题被判定为单跳时，采用带验证的生成：

```

检索 → 生成答案 → LLM 验证 → 通过 → 返回
                                |
                                × 不通过 → 重新生成（最多 1 次重试）

```

验证 Prompt 示例:

Verify whether the following answer is directly supported by the evidence.

Question: ... Answer: ... Evidence: ...

Respond with ONLY 'yes' or 'no'.

7. 评估框架

检索指标

指标	含义
nDCG@k	归一化折扣累积增益 — 排序质量
MAP@k	平均精度均值 — 检索准确性
Recall@k	召回率 — 覆盖度
Precision@k	精确率

QA 指标

指标	含义
EM	精确匹配 — 标准化后是否完全一致
F1	预测与标准答案的 token 重叠度
Joint EM/F1	答案 × 支撑文档 的联合得分

7.1 实验结果

Dense Retrieval (BGE-large) + qwen2.5-7b-instruct

检索指标:

指标	@2	@5	@10
nDCG	0.609	0.737	0.764
MAP	0.539	0.654	0.671
Recall	0.572	0.799	0.866

QA 指标:

EM	F1	Recall	Joint F1
0.335	0.470	0.570	0.229

Dense 检索 nDCG@10 达到 **0.764**, Recall@10 达到 **0.866**

谢谢

Q & A

项目地址: [PolyU-25Fall-COMP5423-RAG](#)